

Segmentación y predicción de siniestros viales en Bogotá D.C.

Informe ejecutivo Proyecto Final de Minería de Datos (KDD sobre la hoja SINIESTROS)

Autor	Erlyn Martínez Ing. de Sistemas	Fecha	25 de agosto de 2026
Dataset	Siniestros Viales Bogotá D.C. (SDM) hoja SINIESTROS	Periodo	2015 – 2020
Registros	196.152 siniestros	Técnicas	Clustering (KMeans) + Clasificación

1. Contexto y objetivo del proyecto

La Secretaría Distrital de Movilidad de Bogotá (SDM) registra cada siniestro vial de la ciudad a través del Informe Policial de Accidentes de Tránsito (IPAT). Este proyecto analiza el histórico 2015-2020 (hoja SINIESTROS, 196.152 registros) para responder dos preguntas de negocio complementarias que apoyan la priorización de recursos de prevención y de infraestructura vial:

- Descriptiva (segmentación): ¿existen perfiles característicos de siniestralidad combinando zona, tipo de vía y momento del día/semana que permitan agrupar los siniestros para focalizar intervenciones?
- Predictiva (clasificación): ¿qué circunstancias del siniestro están asociadas a una mayor probabilidad de que existan víctimas (heridos o muertos) y no solo daños materiales?

2. Los datos

Se trabajó únicamente con la hoja SINIESTROS del archivo oficial de Datos Abiertos Bogotá (196.152 registros × 10 columnas originales: fecha, hora, gravedad, clase de siniestro, tipo de choque, objeto fijo, dirección, localidad y diseño del lugar). Antes de modelar se identificaron y trataron tres problemas reales de calidad de datos:

Problema	Diagnóstico	Tratamiento
Valores faltantes estructurales	CHOQUE (14,4% nulo) y OBJETO_FIJO (96,6% nulo) solo aplican condicionalmente (CLASE=Choque / CHOQUE=Objeto fijo) → mecanismo MAR, verificado con tablas cruzadas	Categoría explícita "No aplica"; los 5 casos MCAR genuinos se imputaron con la moda condicional
Alta cardinalidad	DIRECCION tiene 92.518 valores únicos de texto libre, inmanejable para un modelo	Ingeniería de variable nueva TIPO_VIA (6 categorías) a partir del prefijo vial
Categorías raras	Ej. localidad Sumapaz (7 registros), clase Incendio (25) se validó que son genuinas (rango de dominio correcto) y no errores de captura	Se conservaron sin modificación

No se hallaron filas duplicadas. Las variables categóricas se codificaron con One-Hot (no son ordinales) y las numéricas se escalaron con StandardScaler, ajustado solo con los datos de entrenamiento para evitar fuga de información.

3. Segmentación de siniestros (Clustering)

Se agruparon los siniestros según su contexto físico y temporal (localidad, clase, diseño del lugar, tipo de vía y franja horaria), sin usar la gravedad, para que los segmentos describan circunstancias y no resultados. El número de clusters (K=4) se eligió combinando el método del codo y el Silhouette Score, cuyo segundo máximo local coincide con el punto donde el codo se estabiliza.

Cluster	Perfil	Tipo de vía	Franja / día	Localidad top	% con víctimas
0 (42.439)	Avenidas AM	Avenida	Mañana, entre semana	Kennedy	34,5%
1 (52.663)	Malla local	Calle	Tarde, entre semana	Engativá	33,7% (mín.)
2 (48.945)	Fin de semana	Carrera	Tarde, 100% fin de semana	Kennedy	35,7% (máx.)
3 (52.105)	Carreras norte	Carrera	Tarde, entre semana	Usaquén	35,2%




Figura 1. Composición de cada cluster por tipo de vía, franja horaria, fin de semana y tasa de víctimas.

El tipo de vía y el carácter laboral/fin de semana son los ejes que más diferencian los clusters (la clase de siniestro no diferencia porque "Choque" domina el 85,6% del total, independientemente del segmento). El Cluster 2 el único 100% de fin de semana concentra la mayor tasa de víctimas (35,7%), casi 2 puntos porcentuales por encima del Cluster 1 (malla vial local entre semana, 33,7%). La diferencia es real pero moderada: el contexto por sí solo no separa dramáticamente el riesgo, como se profundiza en la sección 5.

4. Predicción de siniestros con víctimas (Clasificación)

El dataset original no trae una variable de clasificación lista para modelar. Se construyó una variable nueva, SINIESTRO_CON_VICTIMAS (1 = con heridos o muertos, 0 = solo daños materiales), agrupando con criterio de negocio las 3 categorías de GRAVEDAD la distinción operativa que más le importa a la política pública de seguridad vial. El 34,8% de los siniestros del histórico tuvo víctimas.

Se compararon tres algoritmos con validación cruzada estratificada de 5 folds, usando como predictores el contexto del siniestro (localidad, clase, tipo de choque, diseño del lugar, tipo de vía y variables temporales), excluyendo GRAVEDAD para evitar fuga de información:

Modelo	Accuracy	Precisión	Recall	F1	AUC-ROC
Regresión Logística	0,767	0,702	0,572	0,630	0,798
Random Forest	0,781	0,756	0,547	0,634	0,804
HistGradientBoosting ★	0,795	0,916	0,452	0,606	0,809

★ Mejor modelo según AUC-ROC en el conjunto de prueba (no visto durante el entrenamiento). El diagnóstico de sobre/subajuste (comparando entrenamiento vs. prueba) muestra brechas pequeñas en los tres modelos (AUC: -0,001 a 0,014), sin evidencia de sobreajuste severo el techo de desempeño (AUC≈0,80-0,81) refleja que el contexto disponible en el IPAT explica el riesgo de víctimas de forma buena pero no completa.




Figura 2. Curvas ROC de los 3 modelos.




Figura 3. Variables más importantes (Random Forest).

Las variables CLASE y CHOQUE_TRAT (naturaleza del siniestro: choque simple, atropello, volcamiento, etc.) concentran más del 75% de la importancia del modelo muy por encima de localidad, diseño del lugar u hora. Un atropello o un siniestro que no es un choque convencional tiene, por su propia naturaleza física, mayor probabilidad de producir víctimas.

5. Integración: ¿el riesgo varía según el segmento?

Se cruzó la probabilidad de víctimas predicha por el mejor modelo con el cluster de cada siniestro. El resultado es consistente: el riesgo promedio predicho reproduce casi exactamente la tasa real observada en cada cluster (p. ej. Cluster 2: 35,7% real vs. 35,8% predicho), y ambos coinciden en señalar al Cluster 2 (fin de semana) como el de mayor riesgo relativo. Esto confirma que el modelo es internamente consistente con la estructura de los datos, pero también revela un hallazgo clave: la diferencia de riesgo entre clusters es modesta (33,7%-35,7%, solo 2 puntos porcentuales), mientras que la naturaleza del siniestro (clase/tipo de choque) explica una variación mucho mayor a nivel individual. En otras palabras, el clustering responde dónde y cuándo actuar, y el modelo predictivo responde qué tipo de siniestro prevenir son ejes de decisión complementarios, no redundantes.

6. Conclusiones y recomendaciones

1. Priorizar la protección de actores vulnerables (peatones, ciclistas) de forma transversal a toda la ciudad: la naturaleza del siniestro es el factor de mayor peso sobre la gravedad, por encima de la zona o el horario.
2. Reforzar controles de velocidad y alcoholemia en las noches de fin de semana, el segmento de mayor riesgo relativo identificado por el clustering (35,7% de siniestros con víctimas).
3. Diferenciar la estrategia de infraestructura por tipo de vía y franja horaria (avenidas en hora pico de la mañana vs. malla vial local vs. carreras del norte), en vez de una estrategia única para toda la ciudad.
4. Enriquecer el IPAT con variables de comportamiento (velocidad, alcoholemia, uso de casco/cinturón) hoy ausentes en la hoja SINIESTROS para mejorar la capacidad predictiva de futuros modelos (AUC actual $\approx 0,81$, bueno pero mejorable).
5. Usar clustering y clasificación de forma conjunta: el primero prioriza recursos operativos por zona/momento, el segundo prioriza campañas de prevención por tipo de siniestro; combinados permiten intervenciones focalizadas y basadas en evidencia.